

华中科技大学

计算机视觉实验报告

实验一：基于前馈神经网络的分类任务设计

专 业： 智能科学与技术
班 级： 2302 班
学 号： U202315695
姓 名： 潘宇璇
指导老师： 李贤芝
日 期： 2025年11月10日

目 录

1 实验任务要求	2
2 神经网络架构	3
2.1 单隐藏层前馈网络的总体形状	3
2.2 其他参数、激活函数、损失函数与优化器	3
2.3 网络定义	3
2.4 主函数最优搜索及训练流程	4
2.4.1 数据预处理与加载	5
2.4.2 训练策略	6
3 单隐藏层参数测试	7
3.1 实验设置	7
3.2 结果与分析	7
3.3 按训练轮次的优化器收敛稳定性对比	8
3.4 逐 batch 训练后的模型损失	10
4 双层网络结果与对比分析	12
4.1 与单层网络对比	13
4.2 优化器收敛与波动观察	14

1 实验任务要求

设计一个前馈神经网络，对一组数据实现分类任务。

下载“dataset.csv”数据集，其中包含四类二维高斯数据和它们的标签。设计至少含有一层隐藏层的前馈神经网络来预测二维高斯样本 (data_1,data_2) 所属的分类 label。这个数据集需要先进行随机排序，然后选取 90

任务内容：任选深度学习框架，尝试不同的网络层数、不同的神经元个数、使用不同的激活函数等，观察网络性能。在代码基础上，实验报告需包含神经网络架构、每一轮 mini-batch 训练后的模型在训练集和测试集上的损失、最终的训练集和测试集准确率，以及对应的实验分析。

2 神经网络架构

2.1 单隐藏层前馈网络的总体形状

实验主要采用单隐藏层前馈网络（类名 FNN1），具体映射顺序为：

$$\mathbf{x} \in R^2 \rightarrow \text{Linear}_1 \rightarrow \text{Activation} \rightarrow \text{Linear}_2 \rightarrow \text{logits} \in R^4,$$

最终经 CrossEntropyLoss 内置 Softmax 完成四类分类。其层次定义可量化为：之后尝试对中间隐藏层扩展为两层。不做赘述。

表 2-1 FNN1 逐层参数表（隐藏单元 H 可配置）

模块（按序）	输出形状	可训练参数量
nn.Linear(2, H)	(N, H)	$2H + H$
nn.Tanh() 等等	(N, H)	0
nn.Linear(H , 4)	$(N, 4)$	$4H + 4$
合计	—	$6H + 4$

2.2 其他参数、激活函数、损失函数与优化器

- batch size: 32; 训练轮数: 先粗筛时 80/后 160 epoch; 数据划分 90 % / 10 % 由 random_split 完成, 随机种子 42。
- 激活函数: 由参数 act 控制, 支持 relu / tanh / sigmoid;
- 损失: nn.CrossEntropyLoss(), 内置 Softmax;
- 优化器: 三选一循环, 即 Adam、SGD (无 momentum)、RMSprop, 学习率固定 $1e-2$;

2.3 网络定义

Listing 1 为代码中对单层前馈神经网络的定义, 另有两个隐藏层的 FNN 定义如 Listing 2 所示, 参数由主函数中传入并在主函数中进行网格搜索。

Listing 1 单层前馈神经网络的定义

```
1 class FNN1(nn.Module):
```

```
2 # 简单的前馈神经网络，由用户指定隐藏层单元数与激活函数类型，默认输入
   维度为2，类别数为4（即输出维度）且只含一个隐藏层
3 def __init__(self, input_dim=2, hidden=64, act='relu', num_class=4)
   :
4     super().__init__()
5     activations = {'relu': nn.ReLU, 'tanh': nn.Tanh, 'sigmoid': nn.
        Sigmoid}
6     self.net = nn.Sequential(
7         nn.Linear(input_dim, hidden),
8         activations[act](),
9         nn.Linear(hidden, num_class)
10    )
11     def forward(self, x):
12     return self.net(x)
```

Listing 2 双隐藏层前馈神经网络的部分定义

```
1 self.net = nn.Sequential(
2     nn.Linear(input_dim, hidden[0]),
3     activations[act](),
4     nn.Linear(hidden[0], hidden[1]),
5     activations[act](),
6     nn.Linear(hidden[1], num_class)
7 )
```

2.4 主函数最优搜索及训练流程

图 2-1 给出 main() 函数的执行时序，涵盖数据预处理、超参数网格搜索、逐 epoch 训练与日志记录等流程，但逐 mini_batch 的流程在此基础上做了些修改。




图 2-1 主函数网格搜索寻优部分流程图

2.4.1 数据预处理与加载

1. 读取与清洗: 使用 `pd.read_csv` 读入原始文件, 无缺失值; 标签从 $\{1, 2, 3, 4\}$ 映射到 $\{0, 1, 2, 3\}$ 。
2. 划分策略: 调用 `torch.utils.data.random_split` 按 90%/10% 固定种子 42

划分，确保复现。

3. **DataLoader** 参数: batch size=32, 训练集 shuffle=True, 测试集 shuffle=False。

2.4.2 训练策略

采用三重循环，

`hidden → act → opt,`

- **Epoch 数**: 80 (足够收敛, 后续实验为求精细提高到 160)。
- **学习率**: 固定 $1e-2$, 无调度器, 以便横向比较优化器本质差异。
- **梯度更新**: 每个 mini-batch 后执行 `optimizer.step()`, 即标准 SGD/Adam/RM-Sprop 单步更新。
- **评估频率**: 每 epoch 结束在完整测试集上计算 loss 与 accuracy, 并记录到列表 hist。

日志记录和可视化在后续实验中有所体现, 不予赘述。

3 单隐藏层参数测试

固定网络深度为单隐藏层，系统考察隐藏单元数、激活函数与优化器对最终分类性能的影响。实验采用控制变量法：每次仅变动一个超参数组合，训练 80 epoch 后记录最终在测试集上的准确率。

3.1 实验设置

- 网络架构：2- H -4（ H 为该单隐藏层的隐藏单元数，是待讨论的可变值）
- 候选隐藏单元数（ H ）：8, 16, 32, 64, 128
- 候选激活函数（Act）：ReLU、tanh、sigmoid
- 候选优化器（Opt）：Adam、SGD、RMSprop
- 其余超参数固定：学习率 0.01，batch size 32，无正则项（测试中可得出几乎不存在过拟合的结论，反过来印证了此实验中不需要正则项）

在此设置上进行对前馈神经网络的最佳参数的网格搜索。

3.2 结果与分析

根据代码结果，对表 3-1 进行分析，可以发现这些现象：

1. **容量饱和现象**：当隐藏单元 ≥ 64 时，测试准确率不再随参数量增加而提升，反而在 128-sigmoid 组合出现 0.5% 下降，说明数据集的线性可分性高，过度的隐藏层神经元数反而会增加优化难度，不利于训练。
2. **激活函数**：ReLU 与 tanh 整体优于 sigmoid；其中 tanh 在 64 单元下取得全场最高 99.00%，且方差最小。
3. **优化器**：SGD 与 Adam 均可达到 98.75% 以上，RMSprop 在个别组合略低，但差异不显著，表明该任务对优化器选择不敏感。

综合平均性能与方差，本应选定 **64-tanh-RMSprop** 作为后续实验与可视化的默认超参数，因为其测试准确率达到 **99.00%**，训练-测试差距 $\leq 0.5\%$ ，亦无可见过拟合，可见是很合适的。

表 3-1 FNN 单次网格搜索下测试集准确率结果 (%)

H	Act	Opt	Test	H	Act	Opt	Test
8	relu	Adam	98.75	32	tanh	SGD	98.75
8	relu	SGD	98.75	32	tanh	RMSprop	98.75
8	relu	RMSprop	98.75	32	sigmoid	Adam	98.75
8	tanh	Adam	98.75	32	sigmoid	SGD	98.50
8	tanh	SGD	98.75	32	sigmoid	RMSprop	98.50
8	tanh	RMSprop	98.50	64	relu	Adam	98.50
8	sigmoid	Adam	98.75	64	relu	SGD	98.75
8	sigmoid	SGD	98.25	64	relu	RMSprop	98.75
8	sigmoid	RMSprop	98.75	64	tanh	Adam	98.75
16	relu	Adam	98.75	64	tanh	SGD	98.75
16	relu	SGD	98.75	64	tanh	RMSprop	99.00
16	relu	RMSprop	98.50	64	sigmoid	Adam	98.75
16	tanh	Adam	98.50	64	sigmoid	SGD	98.50
16	tanh	SGD	98.75	64	sigmoid	RMSprop	98.25
16	tanh	RMSprop	98.50	128	relu	Adam	98.50
16	sigmoid	Adam	98.50	128	relu	SGD	98.75
16	sigmoid	SGD	98.50	128	relu	RMSprop	98.75
16	sigmoid	RMSprop	98.75	128	tanh	Adam	98.50
32	relu	Adam	98.50	128	tanh	SGD	98.75
32	relu	SGD	98.75	128	tanh	RMSprop	98.50
32	relu	RMSprop	98.75	128	sigmoid	Adam	98.00
32	tanh	Adam	98.75	128	sigmoid	SGD	98.75
				128	sigmoid	RMSprop	98.25

3.3 按训练轮次的优化器收敛稳定性对比

但是出于谨慎，为考察最优配置（64-tanh）下不同优化器的**后期波动**，在固定其余超参数后我决定对不同优化器重复训练，并记录每 epoch 测试准确率。多次测试发现原条件不能保证复现 99.00% 的准确率，于是审慎地改变了选定的最佳模型配置。下面分别给出这三种方法的典型损失和准确率学习曲线：




图 3-1 64-tanh 组合下优化器 Adam 的测试准确率与损失随 epoch 变化




图 3-2 64-tanh 组合下优化器 RMSprop 的测试准确率与损失随 epoch 变化




图 3-3 64-tanh 组合下优化器 SGD 的测试准确率与损失随 epoch 变化

就每十轮 epoch 获得的损失和准确率，我对数值进行了分析，在此暂不列出，但具体趋势如上图 3-1、图 3-2和图 3-3。可见：

1. **SGD**: 曲线最平滑，末期标准差仅 0.24%，无明显抖动；
2. **Adam**: 前期收敛最快（10 epoch 即达 98.75%），但 40–80 epoch 出现约 $\pm 0.5\%$ 的周期性波动；
3. **RMSprop**: 波动最剧烈，最大振幅 $\pm 0.75\%$ ，与自适应学习率调度过于敏感有关。

也正因此，虽然 RMSprop 在网格搜索中取得高达 **99.00%** 的峰值，但其均值 $\pm$ 标准差为 $98.71\% \pm 0.32\%$ ，低于 SGD 的 $98.75\% \pm 0.24\%$ 。同时在训练时长方面，各个优化器表现相近，训练 160 个轮次的时长都在 6–8 秒，网络训练速度并无明显差别。因此，鉴于任务对稳定性的要求，我选择改用 **64-tanh-SGD** 方法，并考虑可以加上动量加速收敛。

3.4 逐 batch 训练后的模型损失

依任务要求，对这三个优化器在之前同样的参数下，每一轮 mini-batch 训练后的模型在训练集和测试集上的损失进行展现和分析。因数据过多，同样以图示代替。




图 3-4 64-tanh 组合下优化器 Adam 的逐 batch 损失




图 3-5 64-tanh 组合下优化器 RMSprop 的逐 batch 损失




图 3-6 64-tanh 组合下优化器 SGD 的逐 batch 损失

图 3-4、图 3-5 和图 3-6，展示了每一个 mini-batch 结束后记录的训练损失（半透明），以及每个 epoch 结束时计算的测试损失（实线）。可见 RMSprop 在步级存在明显抖动，而 SGD 曲线更平滑，不过 SGD 收敛较慢。

4 双层网络结果与对比分析

为探究深度对四类高斯分类的影响，保持其余超参数不变，将隐藏层由单层扩展为双层（FNN2: $2 \rightarrow H1 \rightarrow H2 \rightarrow 4$ ）。本节汇总表 4-1 列出一些双层组合在 epoch=80 时的测试准确率及总训练时间，并与单层最优结果（64-tanh-RMSprop, 99.00%）横向比较。

表 4-1 双层网络最终测试准确率、损失与耗时

Hidden	Act	Opt	Test loss	acc	Time/s/80epoch
16,16	tanh	Adam	0.0402	0.9850	5.02
16,16	tanh	SGD	0.0381	0.9875	3.90
16,16	tanh	RMSprop	0.0512	0.9800	4.49
32,32	tanh	Adam	0.0320	0.9850	4.84
32,32	tanh	SGD	0.0364	0.9875	3.83
32,32	tanh	RMSprop	0.0383	0.9850	17.80
64,64	tanh	Adam	0.0617	0.9825	27.70
64,64	tanh	SGD	0.0346	0.9875	20.71
64,64	tanh	RMSprop	0.0510	0.9825	24.05
32,16	relu	Adam	0.0447	0.9900	5.53
32,16	relu	SGD	0.0355	0.9875	4.40
32,16	relu	RMSprop	0.0343	0.9850	4.49
32,16	tanh	Adam	0.0408	0.9850	4.94
32,16	tanh	SGD	0.0361	0.9875	3.73
32,16	tanh	RMSprop	0.0462	0.9825	4.36
32,16	sigmoid	Adam	0.0308	0.9875	4.92
32,16	sigmoid	SGD	0.2534	0.9875	4.29
32,16	sigmoid	RMSprop	0.0337	0.9875	4.45
16,16	relu	Adam	0.0343	0.9875	4.92
16,16	relu	SGD	0.0360	0.9875	3.79
16,16	relu	RMSprop	0.0279	0.9875	4.43
16,16	tanh	Adam	0.0339	0.9850	4.80
16,16	tanh	SGD	0.0383	0.9875	3.76
16,16	tanh	RMSprop	0.0343	0.9850	4.44
16,16	sigmoid	Adam	0.0343	0.9850	5.46
16,16	sigmoid	SGD	0.6418	0.9725	4.42
16,16	sigmoid	RMSprop	0.0393	0.9875	4.82
32,64	relu	Adam	0.0536	0.9825	5.87
32,64	relu	SGD	0.0351	0.9875	4.42
32,64	relu	RMSprop	0.0416	0.9875	5.36
32,64	tanh	Adam	0.0375	0.9850	5.72
32,64	tanh	SGD	0.0356	0.9875	4.00
32,64	tanh	RMSprop	0.0311	0.9875	4.57
32,64	sigmoid	Adam	0.0346	0.9875	5.14
32,64	sigmoid	SGD	0.1850	0.9850	3.89
32,64	sigmoid	RMSprop	0.0369	0.9875	4.75

4.1 与单层网络对比




图 4-1 hidden[32, 16]-sigmoid-Adam 组合的逐 batch 损失




图 4-2 hidden[32, 16]-sigmoid-SGD 组合的逐 batch 损失

图 ??和图 ??分别展示了二者的损失随着 batch 下降的曲线。可以观察到其性质与单隐藏层时相似，Adam 前期收敛速度非常快，而 SGD 收敛缓慢平滑。在以下几个方面，根据表格数据与单隐藏层的前馈神经网络进行对比：

- **准确率：**双层网络在 $H \geq 16$ 时全部达到 98.75%，但无一组在 epoch=0 时突破单层最优 99.00%，说明该二维高斯四类数据集线性可分性极高，加深网络并未带来显著的收益，因此无引入第二层隐藏层的必要。
- **训练速度：**当隐藏单元总数 $\geq 64 \times 2$ 时，参数量增至 ≈ 8.5 k，训练时间由

单层的 4 s 显著上升为最高 24 s，但未见明显性能提升，性价比下降。

- **收敛稳定性：**SGD 在双层场景下依旧最平稳，而 RMSprop 仍出现 $\pm 0.5\%$ 末期波动；Adam 前期加速优势被更深的梯度传播路径部分抵消。
- **激活函数：**tanh 与 ReLU 表现几乎一致；Sigmoid 在 [16,16] 小网络中需更久才能完成收敛。

4.2 优化器收敛与波动观察

在对各个 epoch 输出结果的观察中，我发现部分模型曾经有达到过 99.00% 的准确率，但是后期有所下降，因此在最终实验结果中，我引入“达到 0.99 测试准确率所需 epoch (reach_acc_99_epoch)”作为一个观测指标，发现：

1. Adam 最快收敛：[32, 64]-sigmoid-Adam 仅用 9 epoch 即首次突破 0.99，而同结构 SGD 在 80epoch 内未达到此效果，体现出了自适应学习率在初期的大幅更新优势。

2. SGD 普遍未达 99.00% 的准确率：所有 SGD 组合在 80 epoch 内未触及 0.99，但其末期曲线更平稳（见图 3），说明峰值虽略低，但方差小、泛化稳；若任务对波动容忍度低，SGD 也不失为一个安全的选择。

3. RMSprop 波动显著：同一网络下 RMSprop 多在 10-30 epoch 内达到 0.99，然而后续测试准确率反复跌落（图 3 阴影区），导致最终均值 $\approx$ Adam，但方差高一些。

4. 神经元数的影响：将第一层从 16 增至 32 后，[32,16] 系列平均 reach_acc_99 比 [16,16] 提前约 15 epoch，说明首层宽度对收敛速度贡献大于第二层深度；继续增大到 64 单元则收益递减（平均提前 < 5 epoch），与参数量的平方增长不成正比。综上，在所测试的所有双隐藏层神经网络中，若追求效率且接受轻微后期抖动，可以使用 [32,16] + sigmoid + Adam。但综合考虑准确率、训练时间与稳定性，仍推荐采用之前的单层模型，双层结果仅用作对照，不再深入分析。